Relatório 2 de Acompanhamento

Identificação de Sistemas Dinâmicos com Modelos de Espaço de Estados Estruturados (SSMs):
comparação com métodos tradicionais de identificação

Gustavo Jae Min Yu – Nº USP 13782762
Ian Seo Takose – Nº USP 13680592
Vinicius Kenji Yamada – Nº USP 13782863

26 de outubro de 2026

Trabalho de Conclusão de Curso – 2º semestre de 2026
Orientação: Felipe Miguel Pait.
Segunda apresentação: 27 de outubro de 2026.

1 Estágio anterior e redirecionamento do trabalho

O relatório 1 (14/09/2026) propôs investigar modelos de espaço de estados estruturados (SSMs) na identificação de sistemas e, depois, seu uso como modelo de previsão em controle preditivo (MPC). Naquela fase o grupo fez apenas um estudo introdutório: as visões contínua, recorrente e convolucional do S4 [2], o mecanismo seletivo do Mamba [3], o papel do HiPPO [4] e uma análise de complexidade. Não havia implementação nem resultado experimental.

Em conversa com o orientador, o objetivo foi delimitado. Em vez de propor identificação *e* controle, o TCC passa a se concentrar na **identificação de sistemas por SSMs, comparada com métodos tradicionais**, para verificar se ela é uma estratégia viável e interessante. O MPC deixa de ser objetivo do trabalho e passa a ser a motivação (*para que* se quer um bom modelo de previsão de vários passos) e uma possível extensão. Este relatório segue a orientação recebida: resume a principal referência encontrada (seção 2), descreve os ensaios realizados (seção 3) e formula a tese a defender (seção 4). A seção 5 traz o cronograma até dezembro. O título foi ajustado ao novo recorte; no relatório 1 ele era "Identificação de Sistemas e Controle Preditivo Baseado em Modelos de Espaço de Estados Estruturados (SSMs)".

2 Referência principal: Mamba como preditor em MPC

O trabalho mais próximo do nosso tema que encontramos é *Mamba Sequence Modeling meets Model Predictive Control*, de M. Cevaal (Tilburg University), T. O. de Jong e M. Lazar (Eindhoven University of Technology), versão 2 de 28/09/2026 [1].

Problema. Redes neurais permitem construir preditores para MPC de sistemas não lineares cujo modelo físico é difícil de obter, mas seu custo computacional limita o uso em tempo real. Segundo os autores, prever bem em horizontes longos continua difícil pelo acúmulo de erro de preditores de um passo, mesmo com redes recorrentes (RNN, LSTM, GRU), e a atenção dos *Transformers* tem custo quadrático no horizonte. Os autores propõem usar a arquitetura Mamba completa como preditor de vários passos e afirmam que isso ainda não havia sido feito; um trabalho anterior usava o Mamba apenas para gerar matrizes de um modelo de Koopman.

Contribuições. (i) Uma descrição matemática completa do bloco Mamba, com uma análise parcial de continuidade Lipschitz voltada a futuras provas de estabilidade; (ii) uma formulação

decoder-only sequência-a-sequência para MPC; (iii) uma implementação em tempo real numa bancada física Quanser Aero2.

Método. O preditor recebe, em cada um dos N passos do horizonte, a entrada futura $u(i|k)$ concatenada à condição inicial $x_0(k)$, e devolve $y(1|k), \ldots, y(N|k)$ numa única passagem. Assim, entrada e saída têm o mesmo comprimento. A condição inicial é o **estado medido** do sistema: os autores observam que um vetor de entradas e saídas passadas poderia substituí-lo, mas não avaliam essa opção. O treino minimiza o erro quadrático normalizado de toda a sequência prevista, isto é, um critério de vários passos. O estado interno da rede é reiniciado a cada instante de controle. O modelo treinado em PyTorch é convertido numa função do CasADi, e o problema de MPC, com custo quadrático de rastreamento e de variação da entrada e restrições de caixa, é resolvido por IPOPT ou SQP. Usam o Mamba original (convolução causal curta e matriz A diagonal real).

Experimentos e resultados. Três sistemas. Nos dois simulados, a comparação é com um MPC baseado em LSTM e, no primeiro, também em *Transformer*; na bancada física, só o Mamba-MPC é avaliado:

- **Oscilador de Van der Pol** (SISO, simulado, $T_s = 0{,}1\,\text{s}$, 40.000 amostras com excitação multisseno): o Mamba-MPC estabilizou o sistema para 100 condições iniciais. No rastreamento, obteve MAE de 0,066 contra 0,072 do LSTM e 0,13 do *Transformer*, com tempo de cálculo por passo de 0,018 s contra 0,20 s e 0,09 s. O tempo cresceu linearmente com o horizonte para Mamba e LSTM e quadraticamente para o *Transformer*. O treino, em contrapartida, levou 400 min para o Mamba, 35 min para o LSTM e 1.200 min para o *Transformer*. Com ruído de medição (relação sinal-ruído 20), o Mamba teve menor erro integrado, porém maior gasto de entrada e maior dispersão; depois do transitório inicial o LSTM rastreou melhor.
- **Quatro tanques** (MIMO, 2 entradas e 4 saídas, simulado): erros menores que os do LSTM com 708 parâmetros contra 2.324, e 0,14 s contra 0,65 s por passo; treino de 400 min contra 180 min.
- **Quanser Aero2** (bancada física, 2 entradas e 3 saídas): rastreamento de referência com 0,038 s de cálculo por passo, dentro do período de amostragem de 0,04 s.

Limitações apontadas pelos autores. Não há prova de estabilidade em malha fechada (os autores observam que o problema de otimização é não convexo); a escolha de reiniciar o estado a cada passo fica em aberto e pode explicar a maior sensibilidade a ruído. Como trabalhos futuros citam: permitir autovalores complexos na matriz A, implementar em *acados* e desenvolver a análise de estabilidade.

Relação com o nosso trabalho. O artigo é o antecedente mais próximo, mas deixa lacunas que orientam o TCC:

1. **Não há comparação com métodos tradicionais de identificação.** As referências são apenas outras redes (LSTM e *Transformer*); não aparecem ARX, NARX, métodos de subespaço ou modelos físicos. (O texto menciona uma comparação com NMPC nos quatro tanques, mas os resultados mostram apenas o LSTM.) Fica sem resposta se o Mamba é melhor do que aquilo que um engenheiro de controle usaria primeiro.
2. **O estado é medido.** O preditor recebe o estado físico como condição inicial. Em identificação por entrada e saída, como no nosso caso, o estado precisa ser reconstruído a partir do histórico medido.

3. **A versão é o Mamba original.** O item "autovalores complexos" da lista de trabalhos futuros é justamente uma das mudanças do Mamba-3 [5], que usamos aqui.
4. **Os resultados principais são de controle em malha fechada.** As perdas de treino e validação relatadas são normalizadas de outra forma e não se comparam diretamente com os nossos erros de simulação.

3 Ensaios realizados

Todos os ensaios usam o mesmo protocolo. Os dados são simulados, o código é próprio e público (`https://github.com/vinikenji10/tcc-ssm`), e cada execução guarda configuração, versões, código e métricas numa pasta própria.

3.1 Protocolo comum

Problema de identificação. Um sistema com uma entrada (força u, em N) e uma saída (posição y, em m) é amostrado com $T_s = 0{,}05\,\text{s}$. No instante t, o preditor conhece u_t e as medições até y_t, e prevê y_{t+1}. Nenhum preditor recebe o estado físico.

Dados. Trinta trajetórias independentes de 2.048 passos (102,4 s), separadas em 20 de treino, 5 de validação e 5 de teste *antes* de qualquer recorte em janelas. Ordens, hiperparâmetros e pontos de parada são escolhidos na validação; o teste é usado uma única vez, depois de congeladas as escolhas.

Previsão e simulação. A avaliação principal é a **simulação de vários passos**: a partir de uma origem t, o modelo recebe as medições até t e as entradas futuras conhecidas, e realimenta as próprias previsões; nenhuma saída real posterior à origem é usada. São 545 origens por conjunto (a partir de $t = 256$, espaçadas de 16 amostras), comuns a todos os modelos, e horizontes de 1, 10 e 50 passos (0,05 s, 0,5 s e 2,5 s). A métrica é a raiz do erro quadrático médio (RMSE) sobre todos os passos até o horizonte, em metros.

Preditores.

- **Persistência**, $\hat{y}_{t+1} = y_t$: referência trivial, que mostra quanto do erro se deve apenas à amostragem fina.
- **ARX**(n_a, n_b): modelo linear nas saídas e entradas passadas, ajustado por mínimos quadrados; ordens $n_a, n_b \in \{2, 4, 8\}$ escolhidas na validação.
- **NARX polinomial**: y_{t+1} como soma de todos os monômios, até o grau g, de $y_t, \ldots, y_{t-n+1}$ e $u_t, \ldots, u_{t-n+1}$; ajuste por mínimos quadrados do erro de um passo; $n \in \{2, 3, 4\}$ e $g \in \{2, 3\}$ escolhidos na validação. É a forma mais simples da família NARMAX [9], referência tradicional em identificação não linear.
- **Rede Mamba-3**: projeção linear de $[u_t, y_t]$ normalizados para 64 canais, um bloco Mamba-3 na sua variante SISO (o termo se refere à estrutura interna do bloco, não ao sistema) [5] com normalização e conexão residual, e projeção para $\hat{y}_{t+1}$; 34.949 parâmetros. Treinada do zero com o erro de um passo (janelas de 512 amostras, AdamW, 300 épocas); taxa de aprendizado (10^{-3}, 3×10^{-3} ou 10^{-2}) e época escolhidas pela simulação de 50 passos na validação; três sementes. Em cada origem, o estado da rede é aquecido com as 256 medições anteriores e depois avança passo a passo.

Implementação do Mamba-3. Os *kernels* oficiais exigem GPU NVIDIA. Os ensaios rodaram num MacBook Air M5, com uma reimplementação em PyTorch construída em torno das funções de referência publicadas pelos autores (repositório `state-spaces/mamba`, *commit* `e9594ce`) [6]. Verificamos que o modo recorrente reproduz o modo de sequência (erro relativo máximo de $2{,}5 \times 10^{-6}$ na GPU do Mac, usada nos treinos), que a rede é causal e que os gradientes são finitos. A equivalência com os *kernels* oficiais, com os mesmos pesos, ainda não foi testada.

3.2 E001 e E002: planta linear

A primeira planta é um massa–mola–amortecedor linear ($m = 1\,\mathrm{kg}$, $c = 0{,}4\,\mathrm{N\,s/m}$, $k = 4\,\mathrm{N/m}$; frequência natural de $2\,\mathrm{rad/s}$ e fator de amortecimento 0,1), excitado por força binária de $\pm 1\,\mathrm{N}$ com patamares de 5 a 40 amostras, sem ruído. Ela serve para verificar o protocolo, porque a resposta ideal é conhecida: uma planta linear de segunda ordem discretizada com segurador de ordem zero satisfaz exatamente uma equação ARX(2,2) [7]. A Tabela 1 confirma isso: o ARX(2,2), escolhido na validação, recupera os coeficientes teóricos e erra apenas no nível de arredondamento. A rede Mamba-3 aprende a dinâmica (erra cerca de 60 vezes menos que a persistência em 50 passos; NRMSE de 2,4 % do desvio-padrão da posição), mas fica muito longe do ARX.

Tabela 1: E001 e E002, planta linear sem ruído: RMSE da trajetória simulada no teste [m]. Rede: média ± desvio-padrão de três sementes.

Modelo	Parâmetros	1 passo	10 passos	50 passos
Persistência	0	$4{,}19 \times 10^{-2}$	$2{,}53 \times 10^{-1}$	$6{,}84 \times 10^{-1}$
ARX(2,2)	5	$8{,}8 \times 10^{-16}$	$2{,}1 \times 10^{-14}$	$1{,}1 \times 10^{-13}$
Mamba-3	34.949	$(1{,}14 \pm 0{,}11) \times 10^{-3}$	$(5{,}86 \pm 0{,}42) \times 10^{-3}$	$(1{,}16 \pm 0{,}10) \times 10^{-2}$

Esse resultado era esperado e não depõe contra a rede: o ARX tem exatamente a estrutura da planta, e a rede precisa descobri-la por otimização, em precisão simples. O ensaio estabeleceu que o protocolo funciona de ponta a ponta para um preditor com memória, mas não informa se o Mamba-3 tem alguma vantagem. Para isso, era preciso um sistema que saísse da estrutura do ARX.

3.3 E003: oscilador de Duffing

O passo seguinte foi uma planta não linear: o mesmo oscilador com uma mola cúbica (oscilador de Duffing),

$$m\ddot{p} + c\dot{p} + kp + k_3 p^3 = u, \qquad y = p, \qquad k_3 = 20\,\mathrm{N/m^3}, \tag{1}$$

integrado por Runge–Kutta de quarta ordem com 10 subpassos por período de amostragem. Para excitar a não linearidade em vários níveis, a força passou a ter amplitude sorteada em $[-2\,\mathrm{N}, 2\,\mathrm{N}]$ a cada patamar (sinal APRBS), em vez de dois níveis. Nas posições visitadas no treino, a força da mola cúbica tem valor eficaz 1,08 vez o da parte linear e chega a 3,6 vezes na maior elongação (0,85 m): a não linearidade é forte (Figura 1). Em relação ao E002 mudam juntos a planta, a excitação e a semente dos dados, de modo que as diferenças entre os dois ensaios não podem ser atribuídas apenas à não linearidade.

Dados, divisão, origens, critérios e rede são os mesmos do E002, a menos da planta e da excitação. A Tabela 2 resume o teste.

Três observações:

- **O ARX deixa de servir.** A validação escolheu a maior ordem da grade, ARX(8,8), e o

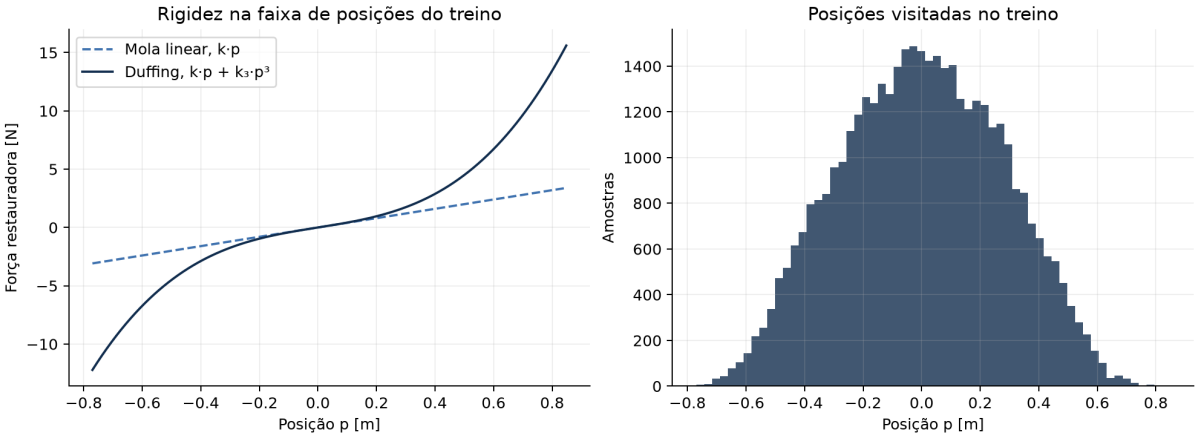


Figura 1: E003. Esquerda: força restauradora da mola de Duffing comparada à parte linear, na faixa de posições do treino. Direita: distribuição das posições visitadas no treino.

Tabela 2: E003, Duffing sem ruído: RMSE da trajetória simulada no teste [m]. Rede: média ± desvio-padrão de três sementes.

Modelo	Parâmetros	1 passo	10 passos	50 passos
Persistência	0	$3{,}47 \times 10^{-2}$	$2{,}04 \times 10^{-1}$	$3{,}80 \times 10^{-1}$
ARX(8,8)	17	$1{,}11 \times 10^{-5}$	$8{,}37 \times 10^{-3}$	$8{,}92 \times 10^{-2}$
NARX(4,4), grau 3	165	$4{,}3 \times 10^{-10}$	$2{,}0 \times 10^{-9}$	$5{,}5 \times 10^{-9}$
Mamba-3	34.949	$(0{,}89 \pm 0{,}25) \times 10^{-3}$	$(6{,}07 \pm 1{,}88) \times 10^{-3}$	$(1{,}53 \pm 0{,}61) \times 10^{-2}$

erro em 50 passos chega a 8,9 cm. Num diagnóstico posterior, ordens até 64 mantiveram o erro em cerca de 8,8 cm: a limitação é de estrutura, não de ordem.

- **O NARX polinomial aproxima o sistema quase até a precisão numérica, sem conter o sistema.** O mapa amostrado de uma equação diferencial com mola cúbica não é um polinômio finito das entradas e saídas passadas; o NARX de grau 3 com dois atrasos, que corresponderia à "estrutura física", erra $1{,}4 \times 10^{-4}$ m na validação. O erro de $5{,}5 \times 10^{-9}$ m aparece com quatro atrasos, numa regressão mal condicionada (posto 137 de 165), e dois dos seis candidatos divergiram na simulação da validação. O grau máximo da grade (3) também foi escolhido sabendo que a mola é cúbica, o que favorece o NARX.
- **A rede fica entre os dois**: $(1{,}53 \pm 0{,}61)$ cm em 50 passos, de 4 a 8 vezes menos que o ARX conforme a semente, sem nenhuma informação sobre a forma da não linearidade. Em termos relativos, o NRMSE passa de 2,4 % na planta linear para 5,4 % no Duffing.

O posto incompleto do NARX vem em boa parte da excitação: com patamares de pelo menos cinco amostras, vários produtos de entradas atrasadas são sempre nulos (só os monômios da entrada têm posto 22 de 35). O sinal não excita persistentemente todos os regressores, e nenhum modelo foi avaliado com entradas que mudam a cada amostra, como as que um MPC produziria. O ensaio também mostra por que a simulação é o critério relevante para o uso pretendido: em um passo, o ARX(8,8) erra *menos* que a rede ($1{,}1 \times 10^{-5}$ contra $8{,}9 \times 10^{-4}$ m), porque oito atrasos de um sinal suave permitem extrapolar bem uma amostra adiante. O erro do modelo errado só aparece quando ele realimenta as próprias previsões.

3.4 E004: Duffing com ruído de medição

O E004 repete o E003 com uma única mudança: ruído gaussiano branco de desvio-padrão 2 cm somado à posição medida, em todos os conjuntos. As trajetórias de força e de posição

verdadeira são as mesmas do E003. O desvio-padrão da posição é de cerca de 28 cm, uma relação sinal-ruído de aproximadamente 14 em amplitude. Os modelos só veem a medição ruidosa: ajuste, normalização, escolha na validação e condições iniciais de cada simulação usam a posição com ruído. No teste, as mesmas previsões são comparadas também com a posição sem ruído, guardada à parte, que mede quão bem cada modelo reproduz a planta (Tabela 3).

Tabela 3: E004, Duffing com ruído de medição (desvio de 2 cm): RMSE da trajetória simulada no teste [m], medido contra a posição *sem ruído*. Entre parênteses, o RMSE de 50 passos contra a medição ruidosa, que tem piso de cerca de 0,02 m.

Modelo	1 passo	10 passos	50 passos	(medição)
Persistência	$4{,}06 \times 10^{-2}$	$2{,}04 \times 10^{-1}$	$3{,}80 \times 10^{-1}$	$(3{,}81 \times 10^{-1})$
ARX(8,8)	$1{,}84 \times 10^{-2}$	$5{,}14 \times 10^{-2}$	$1{,}02 \times 10^{-1}$	$(1{,}04 \times 10^{-1})$
NARX(4,4), grau 3	$2{,}46 \times 10^{-2}$	$6{,}72 \times 10^{-2}$	$1{,}45 \times 10^{-1}$	$(1{,}46 \times 10^{-1})$
Mamba-3	$(9{,}1 \pm 0{,}3) \times 10^{-3}$	$(1{,}13 \pm 0{,}12) \times 10^{-2}$	$(1{,}54 \pm 0{,}28) \times 10^{-2}$	$(2{,}53 \times 10^{-2})$

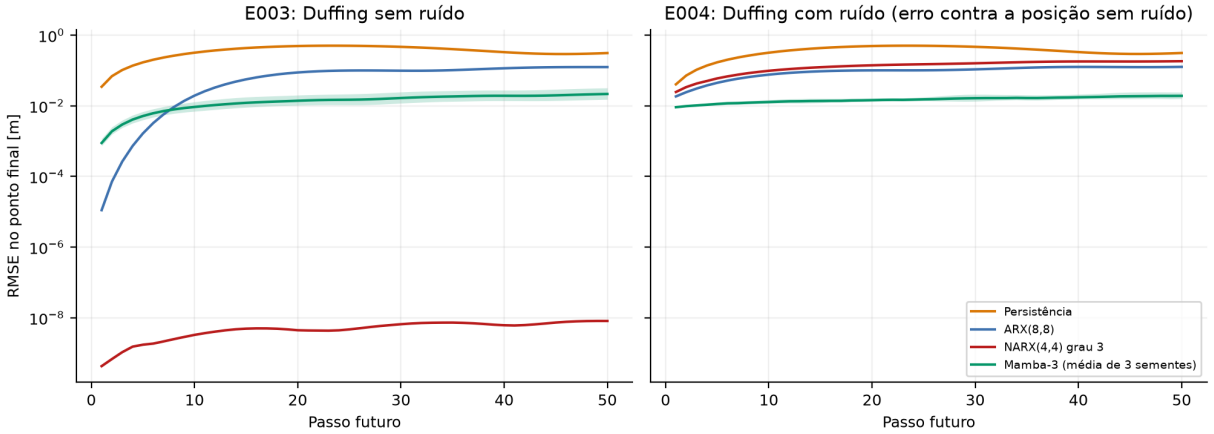


Figura 2: Erro no passo futuro h (RMSE sobre as 545 origens de teste), em escala logarítmica, para os modelos escolhidos nas execuções registradas. No E004, o erro é medido contra a posição sem ruído. Faixa verde: menor e maior valor entre as três sementes da rede. O NARX do E004 é o de quatro atrasos; com mais atrasos ele se aproxima da rede (Tabela 4).

Na execução registrada, o quadro se inverte em relação ao E003: o NARX, que era quase exato, passa a errar 14,5 cm em 50 passos, mais que o ARX (10,2 cm), enquanto a rede mantém praticamente o mesmo erro que tinha sem ruído (a diferença é menor que a dispersão entre sementes). A rede erra 6,6 vezes menos que o ARX e 9,4 vezes menos que o NARX (de 5,5 a 10,6 vezes, conforme a semente; Figura 2). A Figura 3 mostra uma das 545 simulações.

Essa vantagem não se sustenta. Como o NARX escolhido estava na borda da grade ($n \leq 4$), fizemos um diagnóstico posterior ampliando apenas o número de atrasos, com o mesmo ajuste e o mesmo critério de validação (Tabela 4). Esse diagnóstico foi feito *depois* de conhecer o teste do E004; os valores de teste servem para entender o resultado, não para escolher modelos.

Com mais atrasos, o erro do NARX cai rapidamente: com $n = 10$, chega a 1,9 cm no teste, dentro da faixa das sementes da rede (1,4 a 1,9 cm). Com $n = 12$, o modelo empata com a rede na validação e seria o escolhido pelo protocolo, mas diverge no teste; com $n = 14$, diverge já na validação. A vantagem da execução registrada é, portanto, um artefato do limite da grade. O que o E004 mostra é outra coisa:

- O erro do NARX pequeno vem sobretudo de **coeficientes enviesados**: o ajuste por

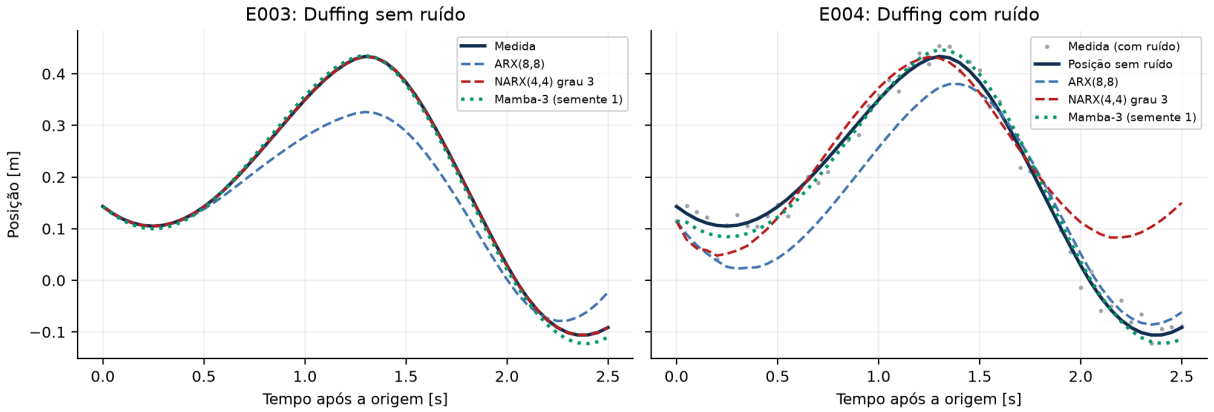


Figura 3: Simulação de 50 passos a partir da primeira origem da primeira trajetória de teste. Até a origem, os modelos recebem medições; depois, só a força futura e as próprias previsões. Mesmo trecho nos dois ensaios; à direita, as medições têm ruído.

Tabela 4: Diagnóstico posterior (E004): NARX de grau 3 com mais atrasos. RMSE da trajetória de 50 passos [m]; validação contra a medição ruidosa (critério do protocolo), teste contra a posição sem ruído. "Diverge": valores não finitos na simulação.

	$n = 4$	$n = 5$	$n = 6$	$n = 8$	$n = 10$	$n = 12$	Mamba-3
Parâmetros	165	286	455	969	1.771	2.925	34.949
Validação	0,149	0,097	0,062	0,034	0,027	0,025	0,025
Teste	0,145	0,094	0,059	0,029	0,019	diverge	0,015

mínimos quadrados de um passo usa saídas passadas ruidosas como se fossem exatas [7, 9]. O mesmo NARX(4,4), simulado a partir de condições iniciais sem ruído, ainda erra 14,3 cm.

- A **condição inicial** também pesa: o NARX(4,4) ajustado aos dados *sem* ruído, quase exato no E003, erra 5,1 cm quando parte de quatro medições ruidosas. A rede, que é aquecida com 256 medições, estima melhor o estado inicial. Parte da sua vantagem vem dessa filtragem, que os métodos tradicionais também podem ter, com estimação do estado inicial ou um observador, mas que não demos a eles.
- O NARX de ordem alta compensa o ruído com milhares de termos, mas é **numericamente frágil**: a validação não protege contra divergência no teste.

3.5 O que os ensaios mostram

Lidos em conjunto, os quatro ensaios sustentam três afirmações e deixam uma em aberto:

1. Com o mesmo tamanho, o mesmo treino e nenhuma informação sobre a planta, a rede Mamba-3 identificou os três cenários sem divergir, com NRMSE de simulação de 50 passos de 2,4 % (linear) e 5,4 a 5,5 % (Duffing, com e sem ruído).
2. Quando a classe tradicional representa bem o sistema e os dados são limpos (ARX na planta linear, NARX cúbico no Duffing), o método tradicional é muito mais preciso e barato: ajuste em menos de 0,2 s, contra cerca de 4 min por treino da rede e 33 a 38 min pela busca completa (três taxas de aprendizado e três sementes).
3. Quando a classe tradicional não representa o sistema (ARX no Duffing), a rede é bem melhor.
4. Com ruído, a comparação com o NARX depende da amplitude da grade e do tratamento da condição inicial. Os dados atuais **não** mostram vantagem da rede sobre um NARX de

ordem suficiente, mas mostram que esse NARX fica frágil.

Limitações.

- **Escopo dos dados:** plantas simuladas de baixa ordem, um único nível de ruído e excitação por patamares, que não excita persistentemente todos os regressores polinomiais.
- **Grades das referências clássicas:** ficaram na borda nos dois casos, e o grau máximo do NARX foi escolhido sabendo que a planta é cúbica. Os modelos tradicionais não tiveram estimação do estado inicial, ajuste pelo erro de simulação nem modelo de ruído.
- **Rede:** uma só configuração de tamanho, treinada apenas com erro de um passo e, provavelmente, por pouco tempo (os melhores *checkpoints* ficaram entre as épocas 240 e 300, de 300).
- **Estatística e uso do teste:** três sementes e cinco trajetórias de teste, com origens sobrepostas, e sem intervalos de confiança. O E004 foi planejado depois de ver o teste do E003, sobre as mesmas trajetórias, e o diagnóstico da Tabela 4 usou o teste do E004.
- **Implementação e referências:** o Mamba-3 não foi comparado com os *kernels* oficiais, e não há comparação com outras redes recorrentes (LSTM, GRU). Por isso o resultado ainda não pode ser atribuído às SSMs em particular.

4 Tese do trabalho

Até o relatório 1, o trabalho tinha um tema, mas não uma tese: "usar SSMs para identificar e controlar sistemas" não diz o que se espera mostrar nem o que contaria como resultado negativo. Com o redirecionamento combinado com o orientador e a evidência dos ensaios, propomos a seguinte formulação, a ser confirmada na apresentação:

> **Tese.** Um modelo de espaço de estados estruturado e seletivo (Mamba-3), treinado apenas com dados de entrada e saída, é uma estratégia *viável* de identificação caixa-preta de sistemas dinâmicos para previsão de vários passos. Ele não supera os métodos tradicionais quando a classe de modelos destes representa bem o sistema e os dados são limpos. Ele é *interessante* se, nos cenários em que os métodos tradicionais exigem escolhas cuidadosas (ordem, termos, tratamento do ruído e do estado inicial), alcançar erro igual ou menor com um procedimento de ajuste padronizado e a um custo aceitável, e se essa vantagem for própria das SSMs, e não de qualquer rede recorrente.

A tese se desdobra em três hipóteses, avaliadas sempre com os mesmos dados, a mesma divisão, o mesmo critério de escolha na validação e a mesma simulação de 50 passos no teste. Os limiares abaixo foram fixados depois dos ensaios deste relatório; valem como critério, sem alterações, para os ensaios seguintes:

H1 – viabilidade. Em todos os sistemas avaliados, a rede atinge NRMSE de simulação de 50 passos de no máximo 10 % no teste, sem valores não finitos em nenhuma semente.

H2 – limite. Quando a classe tradicional representa bem o sistema e não há ruído, o método tradicional tem erro menor que a rede e custo de ajuste ao menos cem vezes menor.

H3 – interesse. Em pelo menos um cenário com ruído, não linearidade não polinomial ou dados reais, o erro médio da rede é menor que o do melhor método tradicional e o da melhor rede recorrente de referência (GRU). Os competidores são escolhidos na validação, a partir de grades definidas antes de ver os dados e sem usar conhecimento da planta. A

diferença precisa superar a incerteza, estimada por *bootstrap* sobre as trajetórias de teste e pela dispersão entre sementes; dentro dessa margem, os resultados são considerados equivalentes.

O que a evidência atual diz.

- **H1** é sustentada: NRMSE entre 2,4 e 5,5 % nos três cenários, sem divergência.
- **H2** também: ARX na planta linear e NARX no Duffing sem ruído foram muito mais precisos, e seu ajuste levou menos de 0,2 s, contra minutos de treino da rede.
- **H3 está em aberto.** Contra o ARX no Duffing, a rede é bem melhor, mas o ARX é uma referência fraca para uma planta não linear. Contra o NARX com ruído, a vantagem inicial desapareceu quando a grade foi ampliada (seção 3). Ainda não há referência recorrente, grade definida antes de ver os dados nem estimativa de incerteza.

A tese pode ser refutada, e isso também seria um resultado do TCC. Se referências tradicionais bem ajustadas, ou uma GRU, igualarem ou superarem a rede de forma consistente nos cenários de H3, a conclusão será que, para sistemas pequenos com uma entrada e uma saída, as SSMs não trazem vantagem que justifique seu custo. Por isso o cronograma (seção 5) prioriza fortalecer as referências antes de ampliar a rede.

5 Cronograma até a entrega final

O cronograma do relatório 1 previa escolher o sistema e o método de comparação até 18/10 e obter as primeiras previsões até 01/11; as duas etapas foram concluídas, e a comparação com referências não lineares, prevista para novembro, foi antecipada (E003 e E004). Com o novo recorte, as etapas de controle saem do cronograma e dão lugar a ensaios que testem a tese.

Período	Atividades e resultados esperados
27/10	Apresentação; registrar o retorno do orientador e da banca sobre a tese e o recorte.
28/10 a 08/11	**Protocolo e referências mais justos.** Fixar, antes de rodar, as grades de todas as famílias, sem usar conhecimento da planta (atrasos até 16, grau até 4). Estimar o estado inicial dos modelos tradicionais com a mesma janela de 256 medições usada pela rede. Ajustar o NARX também pelo erro de simulação e com seleção de termos (mínimos quadrados ortogonais) e incluir uma GRU com o mesmo protocolo. Treinar a rede por mais tempo e também com perda de vários passos. Reservar um conjunto de teste novo, usado uma única vez no fim, e calcular intervalos por *bootstrap*. Repetir E003 e E004 nessas condições.
09 a 15/11	**Onde a estrutura não ajuda.** Não linearidade que não é polinomial (por exemplo, saturação ou atrito), excitação que muda a cada amostra (multisseno) e varredura do nível de ruído e da quantidade de dados de treino. Resultado: curvas de erro em função do ruído e dos dados para cada família.
16 a 22/11	**Dados reais.** *Benchmark* Silverbox [8], circuito eletrônico que implementa um oscilador do tipo Duffing, comparando com os resultados publicados de métodos tradicionais. Resultado: primeira evidência fora de simulação.
23 a 29/11	Custo computacional (treino e simulação de muitas trajetórias), consolidação das tabelas, verificação da implementação do Mamba-3 contra os *kernels* oficiais numa GPU NVIDIA, se houver acesso. Encerrar novos experimentos.
30/11 a 06/12	Redação do relatório final, revisão pelo grupo e pelo orientador, ensaio da apresentação presencial.
07/12 e 08/12	Entrega do relatório final e apresentação presencial (datas a confirmar no Moodle).

Se sobrar tempo, o uso do modelo identificado como preditor num MPC simples pode entrar como demonstração, sem ser critério de sucesso do trabalho.

Referências

[1] CEVAAL, M.; DE JONG, T. O.; LAZAR, M. *Mamba Sequence Modeling meets Model Predictive Control*. arXiv:2604.13857, versão 2, 28 set. 2026. Disponível em: `https://arxiv.org/abs/2604.13857`.

[2] GU, A.; GOEL, K.; RÉ, C. *Efficiently Modeling Long Sequences with Structured State Spaces*. ICLR, 2022. Disponível em: `https://arxiv.org/abs/2111.00396`.

[3] GU, A.; DAO, T. *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. 2023; versão revisada em 2024. Disponível em: `https://arxiv.org/abs/2312.00752`.

[4] GU, A.; DAO, T.; ERMON, S.; RUDRA, A.; RÉ, C. *HiPPO: Recurrent Memory with Optimal Polynomial Projections*. NeurIPS, 2020. Disponível em: `https://arxiv.org/abs/2008.07669`.

[5] LAHOTI, A.; LI, K. Y.; CHEN, B.; WANG, C.; BICK, A.; KOLTER, J. Z.; DAO, T.; GU, A. *Mamba-3: Improved Sequence Modeling using State Space Principles*. arXiv:2603.15569, 2026. Disponível em: `https://arxiv.org/abs/2603.15569`.

[6] STATE-SPACES. *mamba* (repositório de código, licença Apache-2.0), *commit* `e9594ce1c732d97440f0332fdc43170a2294dbfa`, 22 jul. 2026. Disponível em: `https://github.com/state-spaces/mamba`. Acesso em: 17 out. 2026.

[7] LJUNG, L. *System Identification: Theory for the User*. 2. ed. Upper Saddle River: Prentice Hall, 1999.

[8] WIGREN, T.; SCHOUKENS, J. Three free data sets for development and benchmarking in nonlinear system identification. In: *European Control Conference (ECC)*, 2013.

[9] BILLINGS, S. A. *Nonlinear System Identification: NARMAX Methods in the Time, Frequency, and Spatio-Temporal Domains*. Chichester: Wiley, 2013.